

Battle Météorage

Script complet pour l'oral
Weibull AFT calibré + évaluation CG / 3 km sur eval 2023-25

21 mai 2026

Table des matières

1	Introduction (à dire en début d'oral, ≈ 1 min)	3
2	Les données (à dire ≈ 1 min)	3
3	Le modèle Weibull AFT — théorie et formules (à dire ≈ 3 min)	4
3.1	Pourquoi un modèle de survie	4
3.2	La distribution de Weibull	4
3.3	Modèle AFT avec covariables	5
3.4	Maximum de vraisemblance avec censure	5
3.5	Calcul de T_q — temps recommandé	5
4	Feature engineering — 17 variables contextuelles (à dire ≈ 1 min)	6
5	Pourquoi pas une simple moyenne ? (à dire ≈ 1 min)	6
6	Calibration empirique robuste (à dire ≈ 2 min)	7
6.1	Le piège : sous-calibration	7
6.2	Solution en deux étapes : winsorization + monotonie	7
6.3	Résultat final calibré	8
7	Vérification empirique non-paramétrique (à dire ≈ 1 min)	8
8	Évaluation sur eval 2023-25 avec critère opérationnel CG / 3 km (à dire ≈ 3 min)	9
8.1	Pourquoi un nouveau critère	9
8.2	Le modèle en mode opérationnel	9
8.3	Définition d'un incident	9
8.4	Résultats sur eval (973 alertes, 17 037 CG analysables, 385 CG < 3 km)	9

8.5	Deux mesures complémentaires	10
8.6	Exemples concrets d'incidents (à $q = 0,95$)	10
9	Risque empirique non-paramétrique adapté à 3 km	10
10	Démonstration Streamlit (à montrer pendant l'oral ≈ 2 min)	10
11	Limites et perspectives (à dire ≈ 30 s)	11
12	Conclusion (à dire ≈ 30 s)	11
A	Annexe — fichiers livrés	11

1 Introduction (à dire en début d'oral, ≈ 1 min)

Phrase d'accroche

« Bonjour. Nous avons travaillé sur le défi Battle Météorage : peut-on raccourcir la règle des 30 minutes d'alerte orage actuellement appliquée par Météorage, sans augmenter le risque pour le personnel au sol des aéroports ? Notre réponse : un modèle Weibull AFT calibré, validé par une vérification empirique indépendante, qui adapte le temps d'attente au contexte de chaque éclair. »

Le contexte. Quand un éclair **nuage-sol** (CG, pour *cloud-to-ground*) tombe dans un rayon de **20 km** d'un aéroport, Météorage déclenche une alerte. L'aéroport interrompt ses opérations au sol (atterrissages, ravitaillements, manutention). L'alerte est levée **30 minutes après le dernier CG observé**. Chaque nouveau CG remet le compteur à zéro.

Les enjeux. Cette règle est aveugle au contexte : tous les orages reçoivent le même délai forfaitaire.

- **Trop court** = risque de foudroiement du personnel ou d'un aéronef au sol $\rightarrow$ inacceptable.
- **Trop long** = retards de vols et pertes opérationnelles $\rightarrow$ coûteux.

Notre question. Sachant qu'il n'y a pas eu de CG depuis t minutes, quelle est la probabilité qu'un nouveau CG **dangereux** tombe encore ? Si cette probabilité descend sous un seuil acceptable α (par exemple 5 %) au bout de $T < 30$ minutes, on peut remplacer 30 par T et faire gagner du temps aux opérations.

Notre approche en une phrase. Un modèle Weibull AFT entraîné par maximum de vraisemblance sur les inter-arrivées CG, calibré empiriquement, et validé indépendamment par une analyse non-paramétrique.

2 Les données (à dire ≈ 1 min)

Fichier source. `segment_alerts_all_airports_train.csv`, 507 071 lignes, période 2016-2022. Une ligne = un éclair détecté dans 30 km d'un aéroport.

Volumétrie après filtrage. On garde uniquement les CG (`icloud=False`), dans la zone d'alerte (`airport_alert_id` non nul), et on exclut Pise 2016 (système d'enregistrement différent) :

Aéroport	CG	Alertes
Ajaccio	10 647	530
Bastia	13 742	532
Biarritz	9 911	590
Nantes	4 378	206
Pise	15 792	542
TOTAL	54 470	2 400

Structure clé : la notion d'alerte.**Définition d'une alerte Météorage**

- Un CG dans 20 km **démarre** une alerte.
- Toute l'alerte = série de CG espacés de moins de 30 min.
- L'alerte se **ferme 30 min après le dernier CG**.
- Un CG plus tard = **nouvelle alerte** (nouvel `airport_alert_id`).

Implication essentielle (« censure à droite »). Dans une même alerte, le gap entre deux CG consécutifs est nécessairement inférieur à 30 min (sinon l'alerte serait fermée). On ne peut donc **pas observer** de gaps supérieurs à 30 min intra-alerte. C'est ce qu'on appelle, en analyse de survie, de la **censure à droite** : on connaît une borne inférieure (30 min) mais pas la vraie valeur.

À retenir pour l'oral : « Notre cible est par construction censurée à 30 min. C'est exactement ce que les modèles de survie comme Weibull AFT savent gérer. »

3 Le modèle Weibull AFT — théorie et formules (à dire ≈ 3 min)**3.1 Pourquoi un modèle de survie**

L'analyse de survie est née en médecine (temps jusqu'à un événement : décès, rechute) et s'applique parfaitement à notre cas : le « temps jusqu'au prochain éclair ». Trois propriétés cruciales :

1. **Gestion native de la censure** : pour le dernier CG d'une alerte, on n'observe pas la durée jusqu'au prochain CG (l'alerte se ferme). On sait juste qu'aucun CG n'est arrivé pendant au moins 30 min. Cette information est intégrée dans la vraisemblance.
2. **Modèle paramétrique avec covariables** : on relie le temps caractéristique λ aux variables explicatives X via $\log \lambda = \beta_0 + \beta^\top X$ (modèle AFT, *Accelerated Failure Time*).
3. **Quantiles analytiques** : la formule $T_q = \lambda \cdot (-\ln q)^{1/k}$ donne directement le temps d'attente pour un niveau de risque cible.

3.2 La distribution de Weibull**Distribution de Weibull**

Fonction de survie (probabilité d'attendre plus de t minutes) :

$$S(t \mid \lambda, k) = \exp\left(-(t/\lambda)^k\right)$$

Densité et hazard (probabilité instantanée) :

$$f(t) = \frac{k}{\lambda} (t/\lambda)^{k-1} S(t), \quad h(t) = \frac{f(t)}{S(t)} = \frac{k}{\lambda} (t/\lambda)^{k-1}$$

Interprétation des paramètres.

- $\lambda > 0$: **échelle** (temps caractéristique, en minutes). Si $\lambda = 2$, on attend en moyenne 2 min.
- $k > 0$: **forme** (sans unité). Gouverne l'évolution du hazard.

Valeur de k	Hazard	Sens physique
$k < 1$	décroissant	orage qui s'éteint (cas typique)
$k = 1$	constant	loi exponentielle, sans mémoire
$k > 1$	croissant	vieillessement, événements plus probables avec le temps

Sur nos données : $k = 0,745$. Le hazard est décroissant, conforme à l'intuition physique des orages.

3.3 Modèle AFT avec covariables

Pour personnaliser la prédiction par éclair, on lie λ aux 21 variables X :

$$\log \lambda(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_{21} X_{21}$$

Chaque coefficient $\beta_j > 0$ **allonge** le temps caractéristique. Un $\beta_j < 0$ le **raccourcit**.

3.4 Maximum de vraisemblance avec censure

Maximum de vraisemblance (MLE)

On choisit les paramètres (β, k) qui rendent les données observées les plus probables.

Cas 1 : éclair non-dernier ($\delta_i = 1$). On a observé exactement le temps t_i jusqu'au prochain éclair. Le modèle doit donner une forte densité en t_i :

$$\mathcal{L}_i = f(t_i | X_i)$$

Cas 2 : dernier éclair ($\delta_i = 0$, **censure**). On sait juste qu'aucun éclair n'est arrivé pendant 30 min. Le modèle doit donner une forte survie à 30 min :

$$\mathcal{L}_i = S(30 | X_i)$$

Log-vraisemblance totale à maximiser :

$$\ell(\beta, k) = \sum_{i=1}^n \left[\delta_i \log f(t_i | X_i) + (1 - \delta_i) \log S(30 | X_i) \right]$$

En Python :

```
1 aft = WeibullAFTFitter(penalizer=0.05)
2 aft.fit(train_df, duration_col='duration', event_col='event')
3 # .fit() trouve par optimisation numrique le bta et le k
4 # qui maximisent la log-vraisemblance.
```

Listing 1 – Fit du Weibull AFT avec lifelines.

3.5 Calcul de T_q — temps recommandé

Pour un niveau de couverture cible q (ex. 0,99 pour 1 % de risque), on cherche T_q tel que $S(T_q | X) = q$:

$$T_q(X) = \lambda(X) \cdot (-\ln q)^{1/k}$$

À retenir pour l'oral : « Le modèle nous donne, pour chaque éclair et son contexte, le quantile T_q exact : le temps après lequel la probabilité qu'aucun éclair n'arrive est de q . »

4 Feature engineering — 17 variables contextuelles (à dire ≈ 1 min)

On construit 17 variables qui résument le passé de l'orage au moment de chaque éclair. Aucune ne « voit » le futur (pas de fuite).

Catégorie	Variables ($6+3+4+4 = 17$)	Intuition
Rythme	cg_rank, time_since_start, prev_gap, rolling_gap_3, rolling_gap_5, trend_gap	rythme passé $\rightarrow$ avenir
Distance	dist_current, dist_cum_mean, dist_diff	orage qui s'éloigne ?
Intensité	amp_abs, amp_cum_mean, is_negative, pct_neg_cum	polarité et puissance
Saisonnalité	month_sin, month_cos, hour_sin, hour_cos	encodage cyclique

Focus sur rolling_gap_5. Moyenne mobile des gaps entre les 5 derniers CG consécutifs.

- Petit (< 1 min) $\Rightarrow$ orage dense, encore actif $\Rightarrow T_q$ court
- Grand (> 4 min) $\Rightarrow$ orage qui se calme $\Rightarrow T_q$ long

Encodage cyclique pour les variables temporelles :

$$\text{month_sin} = \sin(2\pi \cdot \text{mois}/12), \quad \text{month_cos} = \cos(2\pi \cdot \text{mois}/12)$$

Avant le fit, toutes les variables continues sont standardisées (moyenne 0, écart-type 1).

5 Pourquoi pas une simple moyenne ? (à dire ≈ 1 min)

C'est la question naturelle : pourquoi ne pas juste prendre la médiane des gaps par aéroport ?

C-index (Concordance index)

Mesure la capacité d'un modèle à **ordonner** deux observations selon leur vraie durée. On tire 2 obs au hasard ; si le modèle prédit que la 1re durera plus longtemps et c'est effectivement le cas, on compte 1. Sinon 0. **C-index = moyenne sur toutes les paires.**

- 0,50 = aléatoire (pile/face)
- 1,00 = ordre parfait
- $\geq 0,70$ = bon modèle

Approche	C-index test
1. Constant (médiane globale)	0,5000 (aléatoire)
2. Médiane par aéroport	0,5459
3. P95 empirique par aéroport	0,5424
4. Weibull AFT, dummies aéroport seuls	0,5456
5. Weibull AFT + 17 variables	0,7432

Les baselines simples plafonnent à $\sim 0,55$: elles distinguent les aéroports mais rien à l'intérieur. Notre Weibull AFT atteint 0,7432, soit **+20 points de discrimination**, exclusivement grâce à l'adaptation au contexte par éclair.

Exemple concret. À Ajaccio, deux derniers CG du test :

- **Orage A** (encore actif) : `rolling_gap_5` = 2,07 min, dist = 18,9 km. Weibull AFT prédit T_{99} = 18,6 min.
- **Orage B** (qui se calme) : `rolling_gap_5` = 5,53 min, dist = 10,0 km. Weibull AFT prédit T_{99} = 99,7 min.

La médiane par aéroport donnerait 0,48 min pour les deux : incapable de distinguer.

6 Calibration empirique robuste (à dire ≈ 2 min)

6.1 Le piège : sous-calibration

Calibration des quantiles

Un modèle est **bien calibré** si la fréquence empirique d'événements correspond à la probabilité annoncée. Exemple : si on annonce T_{99} (1 % de risque), seuls 1 % des observations doivent dépasser ce T_{99} .

Sur notre test, le Weibull est sous-calibré :

On annonce	On a vraiment	Écart
10 % risque	21 % risque	$\times 2$
5 % risque	14 % risque	$\times 3$
1 % risque	6 % risque	$\times 6$

Pourquoi ? La queue de Weibull décroît comme $\exp(-(t/\lambda)^k)$ — c'est rapide. Mais les vrais longs silences sont *plus longs* que ce que Weibull prédit. Le modèle est trop optimiste sur les extrêmes.

6.2 Solution en deux étapes : winsorization + monotonie

Étape A — winsorization.

Winsorization : on remplace les valeurs au-dessus du percentile 95 par la valeur du P95 lui-même. Retire l'effet des outliers extrêmes **sans les supprimer**.

```

1 for q in [0.90, 0.95, 0.99]:
2     Tq_pred = aft.predict_percentile(test_evt, p=1.0 - q).values
3     residuals = y_real / np.where(Tq_pred > 1e-9, Tq_pred, 1e-9)
4     p95 = np.quantile(residuals, 0.95)
5     residuals_wins = np.minimum(residuals, p95)
6     c_q_winsorized[q] = np.quantile(residuals_wins, q)

```

Listing 2 – Winsorization des résidus avant calcul de c_q .

Étape B — monotonie de c_q . À $q = 99\%$ on obtient $c_{99}^{\text{wins}} = 1,13 < c_{95} = 2,02$ — ce qui rendrait $T_{99} < T_{95}$, mathématiquement impossible. On impose :

$$c_q^{\text{final}} = \max(c_q^{\text{winsorisé}}, c_{q-1}^{\text{final}})$$

q	c_q^{brut}	$c_q^{\text{winsorisé}}$	c_q^{final}
10 %	1,82	1,82	1,82
5 %	2,02	2,02	2,02
1 %	2,82	1,13	2,02

6.3 Résultat final calibré

$$T_q^{\text{calibré}}(X) = c_q \cdot \hat{T}_q^{\text{Weibull}}(X)$$

- À 10 % de risque : $T = 16$ min (gain de 14 min)
- À 5 % de risque : $T = 26$ min (gain de 4 min)
- À 1 % de risque : $T = 46$ min — au-dessus de 30, on garde la baseline

7 Vérification empirique non-paramétrique (à dire ≈ 1 min)

On dispose d'une approche **complètement non-paramétrique** qui ne fait aucune hypothèse de distribution. Elle sert de **vérification indépendante** du Weibull AFT.

Définition. Soit une alerte A contenant les CG aux instants $t_1 < t_2 < \dots < t_n$.

- Inter-arrivées : $\Delta_i = t_{i+1} - t_i$, pour $i = 1, \dots, n-1$.
- **Plus grand silence intra-alerte** : $G(A) = \max_{1 \leq i \leq n-1} \Delta_i$

Si on avait choisi un temps de maintien $T < G(A)$, on aurait fermé l'alerte **avant** le CG suivant — c'est un incident.

Risque empirique

Pour un T candidat :

$$\hat{R}(T) = \frac{1}{N} \sum_{k=1}^N \mathbb{1}[G(A_k) > T]$$

On cherche :

$$T^*(\alpha) = \min\{T : \hat{R}(T) \leq \alpha\}$$

Tolérance α	$T^*(\alpha)$	Gain vs 30 min
10 %	25 min	+5 min
5 %	28 min	+2 min
1 %	30 min	0 min (= règle Météorage!)

Résultats sur train.

Découverte : à $\alpha = 1$ %, $T^*(1\%) = 30$ min — *exactement* la règle Météorage. La règle des 30 min n'est pas un choix arbitraire : elle est statistiquement bien calibrée pour 1 % de risque résiduel.

8 Évaluation sur eval 2023-25 avec critère opérationnel CG / 3 km (à dire ≈ 3 min)

8.1 Pourquoi un nouveau critère

Les sections précédentes mesuraient le risque sur les CG en zone d'alerte (20 km). Mais le **vrai risque opérationnel** pour un aéroport (personnel sol, ravitaillement) se joue à **quelques kilomètres** de l'aéroport.

Le protocole officiel du Data Battle (`Evaluation_databattle_meteorage.ipynb`) impose donc le critère suivant :

Critère opérationnel officiel

Incident = un éclair à < 3 km de l'aéroport arrivant *après* la fin d'alerte prédite.

Choix raisonné. Nous précisons que seuls les **CG** (nuage-sol) comptent comme incidents : les IC (intra-nuage) ne touchent pas le sol et ne sont pas dangereux pour les opérations sol. Ils peuvent toutefois servir de signal contextuel à l'entraînement.

8.2 Le modèle en mode opérationnel

Règle d'usage : à chaque CG observé en zone 20 km, le modèle Weibull AFT prédit un temps d'attente $T_q(X)$ minutes.

1. Si aucun nouveau CG n'arrive pendant T_q min $\rightarrow$ on lève l'alerte.
2. Si un nouveau CG arrive avant $T_q \rightarrow$ le compteur est remis à zéro.

C'est exactement la règle Météorage 30 min, mais avec T_q adapté au contexte.

8.3 Définition d'un incident

Pour deux CG consécutifs i et $i + 1$ dans la même alerte, soit Δ_i l'écart temporel :

$$\text{incident}_i = (\Delta_i > T_q(X_i)) \text{ ET } (\text{dist}(CG_{i+1}) < 3 \text{ km})$$

Lecture : le modèle a annoncé qu'on pouvait lever à T_q min, mais en réalité le prochain CG arrive après T_q (donc on aurait levé trop tôt) *et* ce CG est dangereux (< 3 km).

8.4 Résultats sur eval (973 alertes, 17 037 CG analysables, 385 CG < 3 km)

q	Cible $1 - q$	Levées avant prochain CG	Incidents	Risque réel
0.90	10 %	2 052	54	14,03 %
0.95	5 %	1 151	37	9,61 %
0.99	1 %	590	15	3,90 %
Baseline 30 min Météorage		—	4	1,04 %

8.5 Deux mesures complémentaires

Important : distinction

On peut mesurer le risque de deux façons. Les deux sont valides et complémentaires.

1. Mesure dynamique (à chaque CG) : la mesure ci-dessus. Simule « que se passerait-il si on appliquait T_q à chaque CG ». C'est ce que la démo Streamlit visualise.

2. Protocole officiel (1 prédiction par alerte au last CG) : on émet une prédiction unique par alerte au format `predictions.csv` et on compte les éclairs < 3 km arrivant après la fin prédite. À $q = 0,95$: risque officiel = 0,60 % (12 / 1 995), gain ≈ 330 heures.

8.6 Exemples concrets d'incidents (à $q = 0,95$)

Aéroport	Alerte	T_q prédit	Δ_i réel	Écart	dist prochain CG
Pise	Pise_1319	2,75 min	35,78 min	+33,03 min	1,87 km
Bastia	Bastia_810	12,93 min	45,87 min	+32,93 min	2,43 km
Ajaccio	Ajaccio_905	7,56 min	37,23 min	+29,67 min	1,44 km
Bastia	Bastia_903	13,46 min	31,20 min	+17,74 min	0,65 km
Biarritz	Biarritz_776	1,97 min	9,28 min	+7,32 min	2,45 km

Lecture pédagogique (à dire à l'oral) : « Sur Pise_1319, le modèle a annoncé qu'aucun CG n'arriverait avant 2,75 min après le dernier CG observé. En réalité, le prochain CG est arrivé 35 min plus tard, à 1,87 km de l'aéroport. Si on avait levé l'alerte à 2,75 min, l'aéroport aurait été en opérations sol pendant 33 minutes avant qu'un éclair dangereux frappe. »

9 Risque empirique non-paramétrique adapté à 3 km

Sur l'eval, dans l'esprit de la section 7 :

$$\hat{R}(T) = \frac{|\{i : \Delta_i > T \text{ ET } \text{dist}(CG_{i+1}) < 3\}|}{N_{CG < 3km}}$$

α visé	$T^*(\alpha)$	Gain vs 30 min
10 %	5 min	+25 min
5 %	9 min	+21 min
1 %	> 30 min	non atteignable

Interprétation à dire : « Cette approche non-paramétrique, indépendante du modèle, confirme qu'un temps fixe inférieur à 30 min peut être tolérable jusqu'à un certain niveau de risque. Pour atteindre 1 % de risque sur les CG dangereux, il faut maintenir la baseline 30 min. »

10 Démonstration Streamlit (à montrer pendant l'oral ≈ 2 min)

Lancement.

```
1 streamlit run app.py
```

Parcours à faire devant le jury.

1. Sélectionner $q = 0,95$ dans la sidebar.
2. Cliquer sur « Lancer l'évaluation ».
3. Lire les KPI globaux : 17 037 CG analysés, 37 incidents, gain $\sim X$ heures, risque réel 9,61 %.
4. Descendre dans « Les 37 incidents détectés », ouvrir le premier : **Pise_1319**.
5. Lire la timeline pas à pas (1 à 5 dans l'app) : « Le modèle a prédit 2,75 min, mais le prochain CG est arrivé 35 min plus tard à 1,87 km. C'est un incident. »
6. Montrer la courbe de risque empirique non-paramétrique en bas.
7. Conclure : « La démo est entièrement interactive : on peut faire varier q et observer le compromis entre gain et risque. »

11 Limites et perspectives (à dire ≈ 30 s)**Limites assumées.**

- Données censurées à 30 min par construction.
- Le modèle prédit le temps jusqu'au *prochain* CG, pas le temps jusqu'au *dernier* CG de l'orage. C'est ce qui explique la différence entre mesure dynamique ($\sim 10\%$ à $q = 0,95$) et protocole officiel ($\sim 0,6\%$).
- Calibration sur le test (en production, prévoir un split train / calibration / test distinct).
- Pas de météo externe (vent, pression, humidité).

Prochaines étapes.

- Intégrer les données météo via API Météo France.
- Re-fit annuel pour absorber la dérive climatique.
- Validation A/B en production.
- Tester le mode **ancillary** (paramètre k variable selon X).

12 Conclusion (à dire ≈ 30 s)**Synthèse pour la conclusion orale**

« Notre Weibull AFT calibré, validé indépendamment par une analyse non-paramétrique, prédit pour chaque éclair un temps d'attente adapté au contexte de l'orage. Sur eval 2023-25, à $q = 0,95$:

- Protocole officiel : **0,60 % de risque** sur les éclairs < 3 km, gain ~ 330 heures.
- Mesure dynamique : **37 incidents visualisables** dans la démo Streamlit.

La démo permet d'inspecter chaque incident en détail. Le code, le rapport et la présentation sont fournis. Merci. »

A Annexe — fichiers livrés

- `Weibull_final3km.ipynb` : notebook principal d'évaluation 3 km
- `weibull_final.ipynb` : notebook de base (théorie + calibration sur train)
- `app.py` : démo Streamlit (lancer `streamlit run app.py`)
- `meteorage_model.py` : module Python réutilisable (load, features, fit)

- `rapport_final.tex` : rapport long
- `presentation_oral.pptx` : présentation PowerPoint
- `script_oral.tex` : ce document